

Matriz de Optimización de Costos

Sistema de Leads VIP con Propuestas (HITL) · Nicolas Navarro

1. Modelo elegido para la tarea real: Claude Haiku 4.5

La tarea del nodo “Calificar y Redactar Propuesta” es clasificación estructurada (VIP sí/no + score de confianza) y redacción de un texto corto y acotado (150-250 palabras, en texto plano) a partir de un prompt con esquema fijo. No requiere razonamiento profundo ni lectura de documentos extensos: es exactamente el perfil de tarea donde conviene el modelo más rápido y económico de la familia, no el más potente. Usar un modelo más caro acá sería pagar de más sin una ganancia de calidad que el cliente perciba. Es el único nodo de IA del flujo: el resto (validación, guard, reintentos del HITL) es lógica determinística que no consume tokens.

2. Consumo real medido

Tokens reportados por n8n para cada llamada a Claude Haiku 4.5 en la corrida de pruebas del 26/09/2026. La entrada incluye el system prompt (catálogo, criterios VIP y reglas de formato), los datos del lead y las instrucciones de formato JSON que agrega el Structured Output Parser.

Ejecución	Tokens de entrada	Tokens de salida	Costo real (Haiku 4.5)
Sofía Paz (#745)	860	371	\$0.0027
Carla Díaz (#746)	835	355	\$0.0026
Diego Torres (#747)	828	412	\$0.0029
Promedio	841	379	\$0.0027

El lead con datos incompletos (#744) no llega a la IA: la validación lo corta antes, con costo de IA cero. Lo mismo un lead que ya no está en “Pendiente” (guard anti-reprocesamiento, #750). Los ciclos de espera del HITL tampoco generan llamadas a la IA: la propuesta se redacta una sola vez por lead.

3. Comparativa de modelos para esta tarea

Modelo	Precio entrada / salida (por MTok)	Costo por lead*	Costo / 1000 leads*	¿Cuándo conviene?
Claude Haiku 4.5 (elegido)	\$1 / \$5	\$0.0027	\$2.74	Clasificación + redacción corta y estructurada — nuestro caso
Claude Sonnet 5	\$2 / \$10	\$0.0055 (2×)	\$5.48	Lectura densa: contratos largos, análisis multi-documento
Claude Opus 5.5	\$4 / \$20	\$0.0110 (4×)	\$10.95	Razonamiento complejo de múltiples pasos; no aplica acá

*Calculado con el consumo promedio medido (841 tokens de entrada y 379 de salida por lead) y los precios estándar publicados por Anthropic (platform.claude.com/docs/en/about-claude/pricing, consultado el 26/09/2026). Es una cota inferior para Sonnet 5 y Opus 5.5: según la misma documentación, los modelos Claude 4.7 y posteriores usan un tokenizador nuevo que genera ~30% más tokens para el mismo texto, lo que llevaría el costo a ~\$0.0071 y ~\$0.0142 por lead respectivamente.

4. ¿Por qué NO usamos Batch API acá?

El Batch API de Anthropic ofrece 50% de descuento sobre entrada y salida, pero procesa las solicitudes de forma asíncrona, con una demora de hasta 24 horas: es para procesos masivos y no urgentes. Nuestro flujo necesita clasificar y notificar al equipo por Slack en segundos, porque el HITL tiene una ventana de aprobación de 5 minutos (5 ciclos de 1 minuto): alguien tiene que poder revisar y aprobar mientras el lead todavía está fresco. Usar Batch acá rompería la experiencia completa. Por eso la decisión correcta fue priorizar velocidad (API estándar) sobre el descuento, aunque técnicamente costaría menos.

5. Dónde SÍ convendría Batch (uso hipotético futuro)

Escenario	Costo estándar / 1000 leads	Costo con Batch / 1000 leads	Ahorro
Reclasificación masiva de leads históricos (ej. limpieza de base de datos)	\$2.74	\$1.37	50%
Reporte mensual de patrones (análisis batch de todos los leads del mes)	\$2.74	\$1.37	50%

Ambos son procesos que no necesitan respuesta inmediata ni HITL en el momento: candidatos ideales para Batch si el volumen creciera lo suficiente como para que el ahorro sea significativo en términos absolutos. (Montos estimados con el mismo consumo promedio por lead; un reporte de patrones real tendría otro tamaño de entrada.)

6. Otros costos de la plataforma

Componente	Uso en el proyecto	Consideración de costo
n8n Cloud	Orquestador; 1 ejecución por lead (los reintentos del HITL ocurren dentro de la misma ejecución)	El plan usado tiene un cupo de 50 ejecuciones/mes para los triggers automáticos. Con más volumen hace falta un plan superior o autohospedar n8n.
Airtable	Base de datos (3 tablas), vista pública de solo lectura y panel en Interfaces	El plan gratuito alcanza para el volumen de pruebas; compartir el panel de Interfaces públicamente requiere un plan pago.
Slack / Gmail	Notificación HITL y envío final	Sin costo adicional en el volumen del proyecto.

7. Conclusión ejecutiva

Con el volumen actual (decenas de leads) la diferencia entre modelos es de centavos, pero el principio escala: a 1000 leads/mes, elegir Haiku 4.5 en lugar de Sonnet 5 ahorra al menos \$2.74 por mes, y a 10000 leads/mes al menos \$27.38 (frente a Opus 5.5, \$82.13), sin pérdida de calidad percibida para esta tarea. A eso se suma el ahorro estructural del diseño: la validación de datos y el guard anti-reprocesamiento evitan pagar llamadas a la IA que no aportan nada. La arquitectura de costos correcta no es “usar siempre el modelo más barato” ni “usar siempre el más potente”: es mapear cada nodo de IA a la complejidad real de lo que tiene que resolver, y no llamar a la IA cuando no hace falta.