

Matriz de Optimización de Costos

Sistema de Leads VIP con Propuestas (HITL) · Nicolas Navarro

1. Modelo elegido para la tarea real: Claude Haiku 4.5

La tarea del nodo “Calificar y Redactar Propuesta” es clasificación estructurada (VIP sí/no) + redacción de un texto corto y acotado (150-250 palabras) a partir de un prompt con esquema fijo. No requiere razonamiento profundo ni lectura de documentos extensos — es exactamente el perfil de tarea donde conviene el modelo más rápido y económico de la familia, no el más potente. Usar un modelo más caro acá sería pagar de más sin ganancia real de calidad, el mismo principio de diseño que se aplicó en el módulo de optimización de costos del curso.

2. Comparativa de modelos para esta tarea

Modelo	Precio input/output (por MTok)	Costo real por lead*	Costo / 1000 leads	¿Cuándo conviene?
Claude Haiku 4.5 (elegido)	\$1 / \$5	\$0.0032	\$3.20	Clasificación + redacción corta y estructurada — nuestro caso
Claude Sonnet 5	\$2 / \$10	\$0.0064 (2×)	\$6.40	Lectura densa: contratos largos, análisis multi-documento
Claude Opus 5	\$15 / \$75	~\$0.048 (15×)	\$48.00	Razonamiento complejo de múltiples pasos, no aplica acá

*Estimado con ~450 tokens de entrada (system prompt + datos del lead) y ~550 de salida (propuesta + JSON), medido sobre las ejecuciones reales de prueba (Ana Martínez, Roberto Fernández). Precios verificados contra la documentación oficial de Anthropic.

3. ¿Por qué NO usamos Batch API acá?

El Batch API de Anthropic ofrece 50% de descuento, pero a cambio de una demora de hasta 24 horas en la respuesta — es para procesos masivos y no urgentes. Nuestro flujo necesita clasificar y notificar al equipo por Slack en segundos (para que el HITL tenga sentido: alguien tiene que poder revisar y aprobar mientras el lead todavía está fresco). Usar Batch acá rompería la experiencia completa. Por eso la decisión correcta fue priorizar velocidad (API estándar) sobre el descuento de Batch, a pesar de que técnicamente costaría menos.

4. Dónde SÍ convendría Batch (uso hipotético futuro)

Escenario	Costo estándar / 1000	Costo con Batch / 1000	Ahorro
Reclasificación masiva de leads históricos (ej. limpieza de base de datos)	\$3.20	\$1.60	50%
Reporte mensual de patrones (análisis batch de todos los leads del mes)	\$3.20	\$1.60	50%

Ambos son procesos que no necesitan respuesta inmediata ni HITL en el momento — candidatos ideales para Batch si el volumen creciera lo suficiente como para que el ahorro sea significativo en términos absolutos.

5. Conclusión ejecutiva

Con el volumen actual de pruebas (decenas de leads), la diferencia entre modelos es centavos — pero el principio escala: a 1000 leads/mes, elegir Haiku en vez de Sonnet ahorra \$3.20/mes sin pérdida de calidad percibida para esta tarea, y a 10.000 leads/mes esa diferencia ya son \$32/mes. La arquitectura de costos correcta no es “usar siempre el modelo más barato” ni “usar siempre el más potente” — es mapear cada nodo de IA del flujo a la complejidad real de lo que tiene que resolver.