

Documentación de Seguridad y Resiliencia

Sistema de Leads VIP con Propuestas (HITL) · Nicolas Navarro

1. Minimización de datos

El sistema solo recolecta los campos estrictamente necesarios para calificar un lead y redactar una propuesta: Nombre, Email, Empresa, Mensaje y Presupuesto estimado. No se piden ni almacenan datos sensibles (documento de identidad, datos de pago, información de salud, etc.) que no aportan nada a la tarea.

Retención: todos los datos viven en una única base de Airtable propiedad del usuario — no hay copias secundarias, exports automáticos ni réplicas en otros sistemas. El único dato que sale de Airtable hacia terceros es el necesario para cada paso puntual: el contenido del lead va a Anthropic solo para la clasificación, y el texto de la propuesta va a Gmail solo para el envío final — ningún proveedor recibe más información de la que necesita para su función específica.

Sin datos hardcodeados: ningún nodo del flujo contiene datos de un lead real escritos a mano. Todo el contenido variable (nombre, empresa, mensaje, presupuesto) viaja por expresiones dinámicas (`{{ "Trigger: Nuevo Lead".item.json.fields.X }}`) — el único texto fijo en el sistema es el catálogo de servicios y las instrucciones de tono, que son configuración del negocio, no datos de clientes.

2. Rutas de error (resiliencia)

2.1 Validación de datos antes de gastar en IA

El primer nodo tras el trigger (“Validar Datos Completos”) verifica que Nombre, Email y Mensaje Original no estén vacíos *antes* de llamar a Claude. Si falta algo, el lead nunca llega al nodo de IA — se registra el fallo en la tabla Errores (con el detalle de qué campos faltaban) y el Lead pasa a Estado=Error. Esto evita dos problemas a la vez: gastar tokens en una llamada que iba a fallar igual, y que un prompt con datos vacíos le genere a la IA una propuesta sin sentido.

2.2 Manejo de fallos de la API de Claude

El nodo “Calificar y Redactar Propuesta” tiene configurado `onError: continueErrorOutput`. Si la llamada a Anthropic falla (timeout, rate limit, error de la API), el flujo no se corta en silencio: la rama de error registra el mensaje de fallo en la tabla Errores (vinculado al lead correspondiente) y marca el Lead como Estado=Error, dejando un rastro claro de que ese lead necesita revisión manual.

2.3 Guarda contra bucles infinitos en el HITL

El punto de espera de aprobación humana (“Pausa: Esperar Aprobación”) vuelve a preguntar cada 1 minuto si el checkbox “Aprobado” ya se tildó. Sin un límite, un lead que nadie aprueba nunca quedaría reintentando para siempre, consumiendo recursos indefinidamente. El nodo “Filtro: ¿Excedió Intentos?” cuenta las veces que se ejecutó la Pausa (`("${Pausa: Esperar Aprobación").all().length`) y, al llegar a 5 intentos sin aprobación, corta el ciclo: marca el Lead como Rechazado y registra el timeout en Errores, en vez de seguir esperando para siempre.

Esta guarda fue validada en vivo: se dejó deliberadamente un lead sin aprobar para confirmar que el sistema realmente corta el ciclo al límite configurado, en vez de asumir que “nunca va a pasar”.

3. Puntos de Human-in-the-loop

El sistema tiene un único punto crítico donde una acción irreversible (contactar a un cliente real) podría ejecutarse sola: el envío de la propuesta por Gmail. Para evitar el “efecto metralleta” (que la IA le escriba directamente a un cliente sin que nadie lo revise), el flujo se detiene ahí de forma obligatoria:

- 1. Generación:** la IA redacta la propuesta y la guarda en Airtable con un checkbox “Aprobado” sin marcar por defecto.
- 2. Notificación:** se avisa al equipo por Slack con el contenido completo de la propuesta para que la revisen sin tener que abrir Airtable a ciegas.
- 3. Espera real:** el flujo literalmente se pausa (nodo Wait) — no hay ningún camino de código que llegue al envío por Gmail sin pasar por el filtro que verifica el checkbox.
- 4. Filtro explícito:** “Filtro: ¿Aprobado?” es la única puerta hacia “Enviar Propuesta (Gmail)”. Si no está tildado, ni siquiera se evalúa la posibilidad de enviar — se recicla al paso 3.

Esto se probó en vivo dejando un lead sin aprobar durante dos ciclos completos (confirmado con “✓2” en los nodos del loop) antes de aprobarlo y ver que recién ahí se disparaba el envío real por Gmail.